[NLP Advanced]

대회 소개

조정호

Upstage

upstage with Fast campus

©2023 by Upstage X Fast campus Co., Ltd. All rights reserved.

Contents

01 대회 설명 03

1.1 대회 소개 04

1.2 데이터 설명 07

1.3 평가 방법 설명 12

02 EDA 17

2.1 대화 데이터 분석 18

01

대회 설명

대회에 대한 개요부터 데이터 구성,
평가방법까지 전반적인 설명

대회소개

DialogSum: A Real-life Scenario Dialogue Summarization

실제 일상생활에서 가능한 다양한 시나리오 multi-turn 대화를 바탕으로 생성 요약문을 만들어보는 대회

- 대화 스타일 : 구어체 (대화형식)
- 대화 Domain : 다양한 주제
- Senario : daily life
- #Dialogs : 13,455 (train 12457, valid 499, test 499)

대회 소개

대회 목표

- 비정형 데이터인 일상 대화 텍스트 데이터를 기반으로 다양한 딥러닝 모델 구축 프로세스를 경험
- 베이스라인 코드를 기반으로 데이터 전처리, 모델 구축 및 평가 파이프라인 전반을 직접 구동 해보는 경험

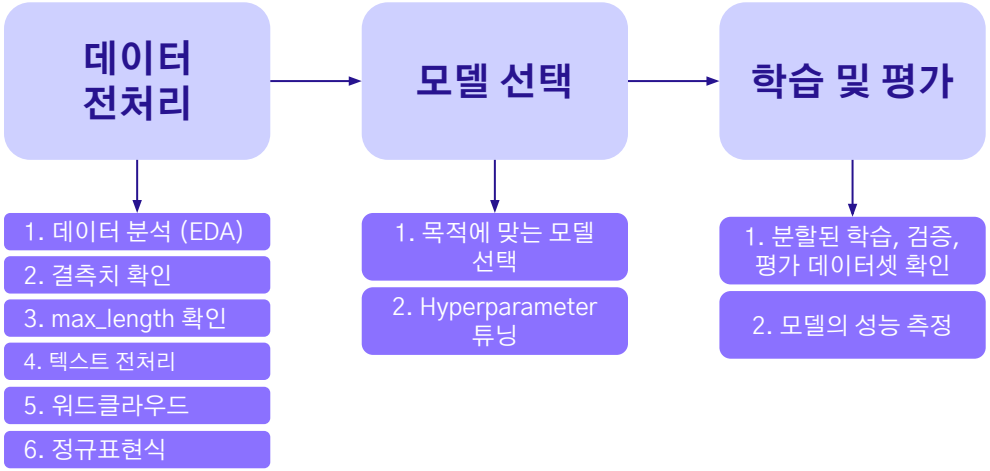

대회 소개

대회 목표

- 데이터 분석 및 분석 결과를 바탕으로 다양한 모델을 fine-tuning해보면서 모델의 성능을 높이는 방법을 경험

[예시]

- (모델 선택) encoder-decoder 모델, encoder-only 모델, decoder-only 모델 등등 다양한 구조의 모델 fine tuning 실험
- (평가) 학습된 모델을 바탕으로 성능 평가, 성능 향상을 위한 전략 수립

데이터 설명

학습 및 검증 데이터

- 타겟 : 일상 대화의 요약
- 데이터의 크기 : 12457, 499, 250, 249 개의 multi-turn 대화

	fname	dialogue	summary
0	train_0	#Person1#: 안녕하세요, 스미스씨. 저는 호킨스 의사입니다. 오늘 왜 오셨나...	스미스씨가 건강검진을 받고 있고, 호킨스 의사는 매년 건강검진을 받는 것을 권장합니...
1	train_1	#Person1#: 안녕하세요, 파커 부인, 어떻게 지내셨나요?\n#Person2#...	파커 부인이 리키를 데리고 백신 접종을 하러 갔다. 피터스 박사는 기록을 확인한 후...
2	train_2	#Person1#: 실례합니다, 열쇠 한 묶음 보셨나요?\n#Person2#: 어떤...	#Person1#은 열쇠 한 묶음을 찾고 있고, 그것을 찾기 위해 #Person2#...
3	train_3	#Person1#: 왜 너는 여자친구가 있다는 걸 말해주지 않았어?\n#Person...	#Person1#은 #Person2#가 여자친구가 있고 그녀와 결혼할 것이라는 사실...
4	train_4	#Person1#: 안녕, 숙녀분들! 오늘 밤 당신들은 정말 멋져 보여. 이 춤을 ...	말릭이 니키에게 춤을 요청한다. 말릭이 발을 밟는 것을 신경 쓰지 않는다면 니키는 ...
...	...	...	...
12452	train_12455	#Person1#: 실례합니다. 맨체스터 출신의 그린 씨이신가요?\n#Person2...	탄 링은 흰머리와 수염으로 쉽게 인식되는 그린 씨를 만나 호텔로 데려갈 예정입니다....
12453	train_12456	#Person1#: 이윙 씨가 우리가 컨퍼런스 센터에 오후 4시에 도착해야 한다고 ...	#Person1#과 #Person2#는 이윙 씨가 늦지 않도록 요청했기 때문에 컨퍼...
12454	train_12457	#Person1#: 오늘 어떻게 도와드릴까요?\n#Person2#: 차를 빌리고 싶...	#Person2#는 #Person1#의 도움으로 5일 동안 소형 차를 빌립니다.
12455	train_12458	#Person1#: 오늘 좀 행복해 보이지 않아. 무슨 일 있어?\n#Person2...	#Person2#의 엄마가 일자리를 잃었다. #Person2#는 엄마가 우울해하지 ...
12456	train_12459	#Person1#: 엄마, 다음 토요일에 이 삼촌네 가족을 방문하기 위해 비행기를 ...	#Person1#은 다음 토요일에 이 삼촌네를 방문할 때 가방을 어떻게 싸야 할지 ...

데이터 설명

학습 및 검증 데이터

- 실제 대화 데이터 구성

전체 대화 내용
#Person1#: 안녕하세요, 스미스씨. 저는 호킨스 의사입니다. 오늘 왜 오셨나요?
#Person2#: 건강검진을 받는 것이 좋을 것 같아서요.
#Person1#: 그렇군요, 당신은 5년 동안 건강검진을 받지 않았습니다. 매년 받아야 합니다.
#Person2#: 알고 있습니다. 하지만 아무 문제가 없다면 왜 의사를 만나러 가야 하나요?
#Person1#: 심각한 질병을 피하는 가장 좋은 방법은 이를 조기에 발견하는 것입니다. 그러니 당신의 건강을 위해 최소한 매년 한 번은 오세요.
#Person2#: 알겠습니다.
#Person1#: 여기 보세요. 당신의 눈과 귀는 괜찮아 보입니다. 깊게 숨을 들이쉬세요. 스미스씨, 담배 피우시나요?
#Person2#: 네.
#Person1#: 당신도 알다시피, 담배는 폐암과 심장병의 주요 원인입니다. 정말로 끊으셔야 합니다.
#Person2#: 수백 번 시도했지만, 습관을 버리는 것이 어렵습니다.
#Person1#: 우리는 도움이 될 수 있는 수업과 약물들을 제공하고 있습니다. 나가기 전에 더 많은 정보를 드리겠습니다.
#Person2#: 알겠습니다, 감사합니다, 의사선생님.

대화 요약문
스미스씨가 건강검진을 받고 있고, 호킨스 의사는 매년 건강검진을 받는 것을 권장합니다.
호킨스 의사는 스미스씨가 담배를 끊는 데 도움이 될 수 있는 수업과 약물에 대한 정보를 제공할 것입니다.

데이터 설명

평가 데이터

- train 데이터 (12457) → dev 데이터 (499) → test 데이터 (250 : 공개, 249 : 비공개)
- Public / Private는 대화 주제에 따라 50% 고르게 선정
- 평가 데이터는 학습 데이터와 달리 dialogue 하나에 summary 3개가 존재

	fname	dialogue	summary1	summary2	summary3
0	test_0	#Person1#: 더슨 씨, 받아쓰기 좀 해주세요. \n#Person2#: 네, ...	더슨 씨는 #Person1#이 모든 직원에게 의사소통 방법을 변경하고 더 이상 즉시...	직원들이 즉시 메시지 프로그램에 시간을 낭비하는 것을 방지하기 위해, #Person...	더슨 씨는 #Person1#의 사무실에서 즉시 메시지 프로그램 사용 금지에 대한 받...
1	test_4	#Person1#: 이 올림픽 공원이 정말 크네요!\n#Person2#: 네. 지금...	#Person1#은 올림픽 스타디움의 크기, 수용량, 그리고 내부 설정에 놀라워한다.	#Person2#는 #Person1#에게 건설 중인 올림픽 스타디움을 보여주고 스타...	#Person2#는 올림픽 스타디움의 완공 시기, 수용량, 그리고 내부 설정을 #P...
2	test_6	#Person1#: 너 무슨 문제 있어? 왜 그렇게 많이 긁고 있어?\n#Perso...	#Person2#가 가렵다고 느낀다. #Person1#은 수두라고 의심하고 #Per...	#Person1#은 #Person2#가 수두에 걸렸다고 의심하고 #Person2#로...	#Person1#은 #Person2#가 수두에 걸렸다고 생각하고 #Person2#에...
3	test_7	#Person1#: 잘 오셨습니다. 무엇을 도와드릴까요?\n#Person2#: 저는...	#Person2#가 체크아웃하고 #Person1#에게 청구서를 요청한다. #Pers...	#Person1#은 세탁 서비스에 대한 잘못된 청구서를 수정하고 #Person2#가...	#Person2#는 자신이 잘못 청구되었다는 것을 발견한다. #Person1#은 청...
4	test_8	#Person1#: 스티븐, 나 정말 당신의 도움이 필요해.\n#Person2#: ...	#Person1#은 스티븐에게 그의 아내를 설득해 이혼하지 않도록 부탁하고 있다. ...	스티븐은 #Person1#이 영원히 충실하다고 맹세하면서 #Person1#의 아내를...	#Person1#은 스티븐에게 그의 아내를 설득해 이혼하지 않도록 부탁하고, 스티븐...
...	...	...	...	...	...
245	test_485	#Person1#: 안녕. 뭐하고 있어? \r\n#Person2#: 별거 없어. 너...	#Person1#와 #Person2#는 서로의 최근 상황에 대해 묻습니다.	#Person1#은 #Person2#의 활동에 대해 묻습니다.	#Person1#은 바쁘고 #Person2#는 유연합니다.
246	test_487	#Person1#: 다음 주에 할아버지 생신이에요. 깜짝 파티를 해야겠어요.\r\n...	#Person1#과 #Person2#는 할아버지의 생일을 논의합니다. 그들은 파티를...	#Person1#과 #Person2#는 할아버지의 생일을 위한 깜짝 파티를 계획하고...	다음 주에 #Person1#과 #Person2#의 할아버지 생신입니다. #Perso...
247	test_489	#Person1#: 나는 시골이 이렇게 시끄러울 줄 몰랐어!\r\n#Person2#...	캐시는 소음에 대해 불평하고 #Person2#는 이것이 17년에 한 번씩 나타나는 ...	캐시는 이 기간에 새들이 나타나서 북캐롤라이나 산맥의 시골이 너무 시끄럽다고 생각하...	캐시는 새들의 울음소리에 짜증이 난다. 새들은 대부분 시원할 때 나오고 주로 나무에...
248	test_492	#Person1#: 테드, 올해 휴가 어디로 가려고 해?\r\n#Person2#: ...	#Person1#와 테드는 휴가에 대해 이야기한다. 테드는 집에 머무를 예정이고 #...	테드와 #Person2#는 휴가를 보낼 장소에 대해 논의하고 있다.	테드의 아내는 몇 주 동안 부모님과 함께 있을 예정이지만, 테드는 그들과 함께 사는...
249	test_496	#Person1#: 어떻게 컨트리 음악에 관심을 가지게 되었나요? \r\n#Perso...	#Person2#는 #Person1#에게 컨트리 음악에 관심을 가지게 된 이유와 프...	#Person2#는 과거의 경력을 공유하는데, 이는 완전히 컨트리 음악과 얽혀 있습니다.	#Person2#는 #Person1#에게 다른 종류보다 컨트리 음악을 더 많이 사고...

데이터 설명

평가 데이터

- 평가 데이터는 학습 데이터와 달리 dialogue 하나에 summary 3개가 존재
- 3개의 summary에 대해서 개별적으로 점수를 산출한 뒤, 종합하여 최종 평가에 활용

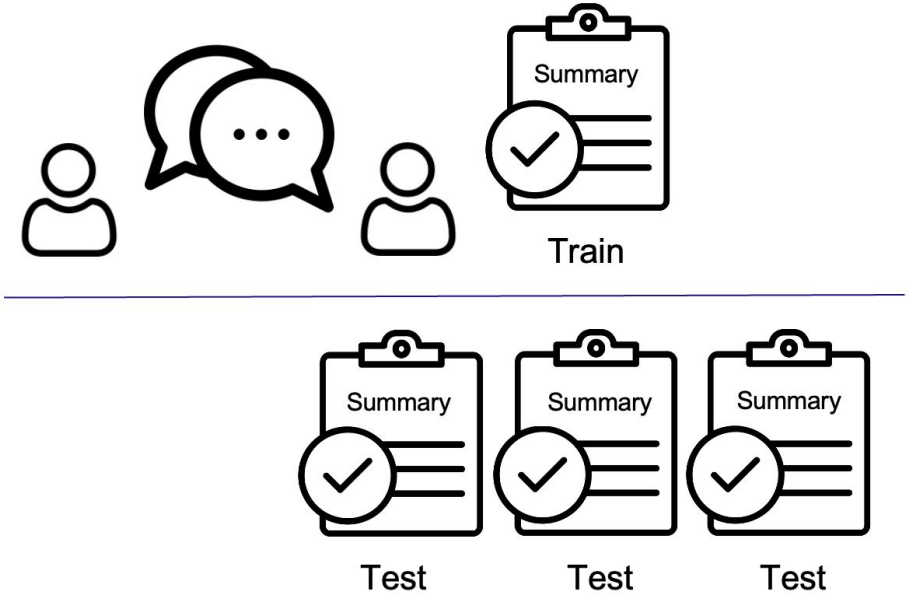

데이터 설명

정답 요약문을 작성할 때의 주요 기준

(1) 대화의 가장 중요한 정보를 전달

(2) 간략하게(대화 길이의 20% 이내)

(3) 대화 내에서 중요한 명명된 개체를 보존 (사람 이름, 기업명 등)

(4) 관찰자의 관점에서 작성 (화자의 의도를 이해하고 작성)

(5) 은어나 약어 없이 공식적으로 사용되는 언어로 작성

평가 방법 설명

평가 방법

- 평가지표는 ROUGE(Recall-Oriented Understudy for Gisting Evaluation) 사용

$$\text{Score} = \frac{\sum_i^N \text{ROUGE-1-F1}(\text{pred}, \text{gold}_i)}{N} + \frac{\sum_i^N \text{ROUGE-2-F1}(\text{pred}, \text{gold}_i)}{N} + \frac{\sum_i^N \text{ROUGE-L-F1}(\text{pred}, \text{gold}_i)}{N}$$

평가 방법 설명

ROUGE-N

$$\text{Recall} = \frac{\text{Gold와 Pred의 겹치는 N-gram 수}}{\text{Gold의 N-gram 수}} \qquad \text{Precision} = \frac{\text{Gold와 Pred의 겹치는 N-gram 수}}{\text{Pred의 N-gram 수}} \qquad \text{ROUGE-F1} = \frac{2 \times \text{Recall} \times \text{Precision}}{\text{Recall} + \text{Precision}}$$

ROUGE-1

Gold: the cat was under the bed

Pred: under the bed there was the cat

Gold 1-grams: [the] [cat] [was] [under] [the] [bed]

Pred 1-grams: [under] [the] [bed] [there] [was] [the] [cat]

$$\text{Recall} = \frac{6}{6} \qquad \text{Precision} = \frac{6}{7} \qquad \text{ROUGE-1-F1} = \frac{2 \times \text{Recall} \times \text{Precision}}{\text{Recall} + \text{Precision}} \approx 0.923$$

평가 방법 설명

ROUGE-N

$$\text{Recall} = \frac{\text{Gold와 Pred의 겹치는 N-gram 수}}{\text{Gold의 N-gram 수}} \qquad \text{Precision} = \frac{\text{Gold와 Pred의 겹치는 N-gram 수}}{\text{Pred의 N-gram 수}} \qquad \text{ROUGE-F1} = \frac{2 \times \text{Recall} \times \text{Precision}}{\text{Recall} + \text{Precision}}$$

ROUGE-2

Gold: the cat was under the bed

Pred: under the bed there was the cat

Gold 2-grams: [the cat] [cat was] [was under] [under the] [the bed]

Pred 2-grams: [under the] [the bed] [bed there] [there was] [was the] [the cat]

$$\text{Recall} = \frac{3}{5} \qquad \text{Precision} = \frac{3}{6} \qquad \text{ROUGE-2-F1} = \frac{2 \times \text{Recall} \times \text{Precision}}{\text{Recall} + \text{Precision}} \approx 0.545$$

평가 방법 설명

ROUGE-L

$$\text{Recall} = \frac{\text{가장 긴 공통부분 문자열의 길이}}{\text{Gold의 1-gram 수}}$$

$$\text{Precision} = \frac{\text{가장 긴 공통부분 문자열의 길이}}{\text{Pred의 1-gram 수}}$$

$$\text{ROUGE-F1} = \frac{2 \times \text{Recall} \times \text{Precision}}{\text{Recall} + \text{Precision}}$$

Gold: the cat was under the bed

Pred: under the bed there was the cat

Gold: the cat was under the bed

Pred': the cat under the bed

$$\text{Recall} = \frac{3}{6} \qquad \text{Precision} = \frac{3}{7} \qquad \text{ROUGE-L-F1} = \frac{2 \times \text{Recall} \times \text{Precision}}{\text{Recall} + \text{Precision}} \approx 0.462$$

평가 방법 설명

토큰화

- 조사 등이 띄어쓰기로 구분되지 않는 한국어의 특성을 고려
- 의미를 갖는 최소 단위인 형태소 단위로 문장을 쪼개어 점수 산출에 활용

[Original text]

호킨스 의사는 매년 건강검진을 받는 것을 권장합니다.

[Tokenized text]

호킨스 의사 는 매년 건강 검진 을 받 는 것 을 권장 합니다 .

02

EDA

학습데이터의 분석

대화 데이터 분석

대화 데이터

- 입력 대화, 요약문 전체적으로 Right-skewed 된 모습
- 입력 대화와 요약문은 길이가 큰 차이

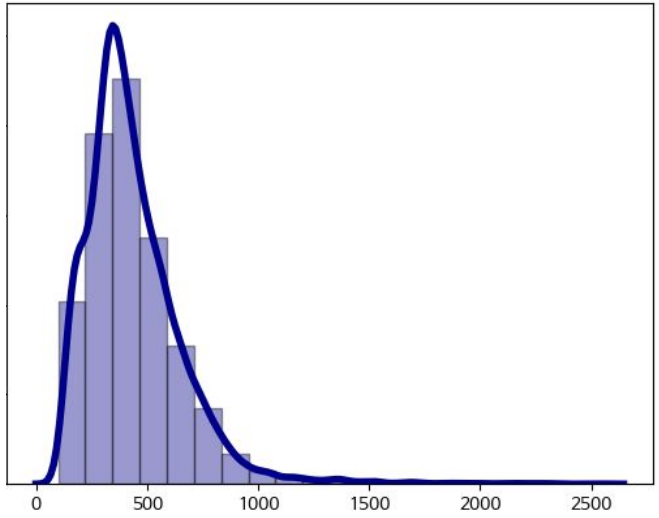

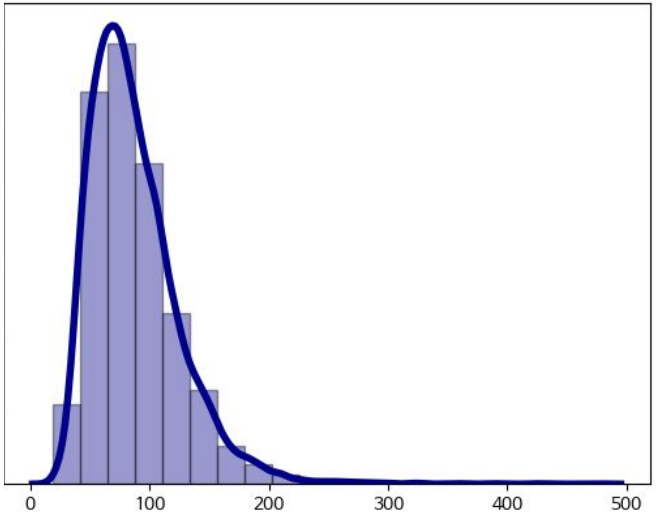

대화 데이터 분석

채팅 대화와의 차이점

- 채팅 대화에서는 약어(ETA, BWT…) 나 이모티콘 (:), ^^ …) 이 쓰이는 반면 대회 데이터는 formal style을 가짐.
- 일상 대화, 쇼핑, 전화 통화 등의 일상 대화 뿐만아니라 business 주제도 다루고 있어 업무, 개인적으로 모두 유용한 데이터

대화 데이터 분석

주요 대화 주제

- 상위 30개 주제를 추출하여 비율 확인
- 일상 대화, 쇼핑, 전화 통화 등의 주제가 많음

대화 데이터 분석

개인정보 마스킹

- 전화번호, 주소, 생년월일, 여권번호, 사회보장번호, 신용카드 번호, 차량 번호,이메일 주소

```
개인정보 내역을 마스킹함
전화번호 → #PhoneNumber#
주소 → #Address#
생년월일 → #DateOfBirth#
여권번호 → #PassportNumber#
사회보장번호 → #SSN#
신용카드 번호 → #CardNumber#
차량 번호 → #CarNumber#
이메일 주소 → #Email#
```

End of Document

Thank you

본 콘텐츠를 어떠한 경로로든 외부로 일부 또는 전부를 복사, 복제, 판매, 재판매, 공유 등을 할 수 없습니다.
이를 위반하는 경우, 지식재산권 침해 및 관련 법률에 따라 책임을 질 수 있습니다.